Sistema de detección temprana del riesgo académicoen estudiantes universitarios mediante Machine Learning

Integrantes:
Valentina Bello Olarte
William Gómez Marín

Programa:
Ciencia de Datos
Universidad Externado de Colombia

Asignatura:
Machine Learning II

Docente:
Wilmer Dario Pineda Rios

Entrega:
Informe técnico final
Modelo, interpretación y despliegue

Bogotá, Colombia
2026

1. Modelo final y reproducción del método del artículo

El modelo final es HistGradientBoosting pues fue el que mejor detectó estudiantes en riesgo en la validación de F2 ya que obtuvo 0.958 y sobre datos que nunca vio detectó 645 de 664, es decir un 97.1%.

Como se dividieron los datos:

Antes de entrenar se aparta una parte de los datos que el modelo no ve mientras aprende y así sacamos el conjunto de prueba o hold-out. Lo hicimos porque si el modelo viera esas respuestas antes de ser evaluado claramente tendría una nota inflada que no refleja lo que pasaría con estudiantes nuevos, generando fuga de datos.

Un problema que sí tenemos es que nuestra base hace la fuga más probable, ya que los 4.000 registros reales corresponden a solo 834 perfiles distintos porque hay hasta 398 copias de un mismo perfil, mientras que los 1.000 sintéticos son todos únicos pero hechos a base de esos perfiles únicos. Identificamos el problema de que si una copia cae en entrenamiento y otra en prueba el modelo reconoce la respuesta sin haber aprendido nada útil. Para solucionar ese problema dividimos con StratifiedGroupKFold (5 pliegues, semilla 42, usando el primer pliegue como prueba), que mantiene en un grupo a los registros idénticos y conserva una proporción parecida de clases para tener 3.969 registros de entrenamiento y 1.031 de prueba (20,6 %) sin ningún perfil compartido. La prueba incluye 833 registros reales y 198 sintéticos; como un grupo no se puede partir, el tamaño no es exactamente 20 % para los datos de evaluación y la proporción en riesgo difiere en 58,4 % en entrenamiento y 64,4 % en prueba.

Como elegimos el modelo final

Comparamos seis opciones: una línea base que predice siempre “en riesgo”, ya que tiene un porcentaje un tanto más alto que “no en riesgo”; regresión logística; SVM con kernel RBF; Random Forest; HistGradientBoosting; y Random Forest con 30 variables seleccionadas. Además, usamos validación cruzada anidada sobre la parte de datos en el entrenamiento, que básicamente es que el examen se repite 5 veces con cortes distintos y dentro de cada uno otra vuelta de 3 cortes escoge los hiperparámetros para que los ajustes nunca se elijan mirando el examen que evalúa el modelo. Usamos F2, que combina recall y precisión, pero le da más peso a recall, y esta métrica nos ayudó también a elegir los hiperparámetros.

Elegimos HistGradientBoosting por cuatro razones: tiene el mejor recall y el mejor F2; es el más estable, con desviación de 0,007 en F2; el mismo ajuste ganó en los 5 pliegues de la validación cruzada; y, al estar basado en árboles, se puede explicar con SHAP. Su ventaja en F2 frente a SVM y Random Forest es de unos 0,02. Random Forest es el mejor evitando falsas alarmas, con especificidad 0,991 y ROC-AUC 0,995, pero deja pasar más estudiantes en riesgo, que es el error que más nos preocupa. La regresión logística queda 0,024 por debajo en F2.

La configuración definitiva usada en boosting fue tasa de aprendizaje de 0,1, profundidad máxima de 6, 200 iteraciones y class_weight="balanced", con semilla 42 para poder repetir los resultados.

Resultado final sobre el conjunto de prueba

El modelo se evaluó una sola vez sobre los 1.031 registros apartados, que no se usaron para ajustar nada. El modelo ganador tuvo 0,973 de accuracy, 0,986 de precisión, 0,971 de recall, 0,975 de especificidad, 0,979 en F1, 0,974 en F2 y 0,991 en ROC-AUC.

En la matriz de confusión, de 664 estudiantes en riesgo el modelo detectó 645 (97,1 %) y no detectó 19 (2,9 %). De 367 sin riesgo, 9 fueron señalados por error como en riesgo (2,5 %). Un ROC-AUC de 0,991 significa que, si se toma al azar un estudiante en riesgo y uno sin riesgo, el modelo asigna mayor riesgo al correcto el 99,1 % de las veces.

Como las categorías originales del dataset eran cinco —riesgo muy bajo, riesgo leve, riesgo medio, riesgo alto y casi segura—, algo que se le dificulta a nuestro modelo elegido es diferenciar entre un estudiante en riesgo leve y uno en riesgo medio. Ese corte fue una decisión que nosotros tomamos para dividirlas en dos categorías, tal como en nuestro artículo guía, y ahí se le dificulta; con casos claros el modelo casi no falla.

Qué se reprodujo del artículo y qué adaptamos

El artículo base de California State University, Fullerton predice qué estudiantes están at-risk con clasificación supervisada, compara varios algoritmos y prueba técnicas para el desbalance. Nosotros conservamos ese propósito y esa lógica, pero los adaptamos a datos colombianos de la Universidad Cooperativa de Colombia (UCC), con unas diferencias:

Aspecto	**Artículo de referencia**	**Adaptación del proyecto**
Datos	119 estudiantes y 31 variables.	5.000 registros y 313 variables predictoras en la versión final del modelamiento.
Variable objetivo	At-risk definido mediante nota actual D o inferior y curso repetido.	Cinco niveles de riesgo agrupados en dos clases: riesgo medio/alto/casi segura = 1; muy bajo/leve = 0.
Modelos	SVM, Naive Bayes, KNN, regresión logística, árbol de decisión y Random Forest.	Baseline, regresión logística, SVM RBF, Random Forest, HistGradientBoosting y Random Forest top-30.
Validación	Train-test split y validación cruzada de 10 pliegues.	Validación cruzada anidada 5×3 y partición agrupada.
Métricas	Accuracy, precisión, recall, F1 y ROC.	Se añadieron especificidad y F2 para priorizar la detección de casos en riesgo.

La variable objetivo cambió porque la base de la UCC no trae notas ni repetición de cursos; por eso usamos el nivel de riesgo de deserción que ya traía la base de datos. Esto mantiene la idea del artículo de identificar al estudiante en riesgo, pero con otra definición. Los resultados son coherentes con la exploración del artículo en cuanto a que los modelos basados en árboles quedaron entre los mejores, aunque no se pretende reproducir exactamente sus resultados.

Con respecto a SMOTE o ADASYN, el artículo las aplica porque su clase en riesgo es minoritaria (21 de 119 estudiantes, cerca de 18 %). En nuestra base la clase en riesgo es mayoritaria (aproximadamente 59,6 % en la base consolidada inicial), y al agrupar las cinco categorías el desbalance es moderado. Además, las variables son dummies y estas técnicas podrían generar valores intermedios sin sentido, como 0,4 en una variable que solo puede ser 0 o 1. La base ya incluye registros sintéticos, por lo que una segunda capa de datos fabricados dificultaría verificar su realismo. En vez de estas técnicas, los modelos —excepto baseline— se entrenaron con class_weight="balanced", y la selección se hizo con F2, que prioriza recall.

2. Interpretación de resultados

La interpretación del modelo se abordó mediante dos procedimientos complementarios: importancia por permutación y SHAP. La importancia por permutación mide cuánto disminuye el desempeño cuando se altera una variable del conjunto de prueba; SHAP permite descomponer la predicción del modelo en contribuciones asociadas a las variables. Estos procedimientos describen patrones utilizados por el modelo y no demuestran relaciones causales.

Factores con mayor influencia

En el análisis de permutación destacaron r_carrera, d_acad, per_profesores, autopercepcion y recomendación_u, junto con variables relacionadas con el apoyo familiar y las horas semanales. En el análisis SHAP también aparecieron con alta importancia variables de desempeño académico, percepción de la experiencia universitaria y acompañamiento. Entre las variables con mayor contribución global se encontraron e_acad_Demasiado, recomendación_u_8, aban_inter_No, autopercepcion_Totalmente, d_acad_Muchas veces, a_profesores_Siempre dispuestos a ayudar y a_familiar_Mucho.

En términos del contexto universitario, estos resultados sugieren que el modelo utiliza información de desempeño académico, percepción del estudiante sobre su experiencia, interacción con profesores, acompañamiento y apoyo familiar para estimar el nivel de riesgo. La importancia global no indica por sí sola que una respuesta aumente o reduzca el riesgo en todos los casos; la dirección y magnitud de una contribución dependen del valor observado y de las demás características del perfil.

Errores e implicaciones prácticas

En la evaluación final reportada para el conjunto de prueba de 1.031 registros, el modelo identificó 645 de los 664 casos etiquetados como en riesgo y dejó 19 sin detectar. También señaló como riesgosos 9 registros que pertenecían a la clase sin riesgo. Los falsos negativos son especialmente relevantes para un sistema de alerta temprana porque representan estudiantes que, según la etiqueta disponible, no serían priorizados por el modelo. Los falsos positivos pueden generar revisiones o contactos innecesarios, por lo que una intervención humana debe confirmar el contexto antes de actuar.

La elección de F2 responde a esta prioridad: otorga más peso al recall que a la precisión, buscando reducir los casos en riesgo que quedan sin identificar. Sin embargo, ninguna métrica elimina por completo los errores. En una implementación institucional, los resultados deben usarse como señal de apoyo para ofrecer acompañamiento, nunca como fundamento único para sanciones, restricciones o decisiones académicas.

Alcance de la interpretación

La variable objetivo representa una clasificación de riesgo incluida en el conjunto de datos y transformada por el equipo a dos clases; no corresponde a un registro longitudinal de deserciones efectivamente ocurridas. Por tanto, las variables identificadas por SHAP describen cómo el modelo reproduce esa clasificación y no deben presentarse como causas de abandono. Además, la interpretación depende de la calidad, representatividad y codificación de los datos disponibles.

3. Despliegue básico

El despliegue se implementó mediante AULA, una aplicación desarrollada en Python con Streamlit que permite consultar el modelo entrenado y presentar sus resultados en una interfaz. La aplicación carga el artefacto del modelo, los datos de prueba y los archivos de información necesarios; comprueba la correspondencia entre las columnas de entrada y las variables esperadas por el modelo; y calcula predicciones y probabilidades para generar las métricas y visualizaciones disponibles.

La estructura del paquete de entrega incluye app.py, requirements.txt, una carpeta modelo/ con modelo_final.joblib, X_test.csv, y_test.csv, informacion_modelo.json y columnas_modelo.json, además de una carpeta imagenes/ con las visualizaciones y archivos de interpretabilidad SHAP. La aplicación utiliza las columnas exportadas del flujo de entrenamiento, por lo que la entrada debe conservar los nombres y el orden esperado por el modelo. No se debe reconstruir manualmente la codificación de variables a partir de respuestas sin aplicar el mismo preprocesamiento del entrenamiento.

Requisitos y ejecución

Para ejecutar la aplicación se requiere Python y las dependencias declaradas en requirements.txt. Desde una terminal, se debe descomprimir el paquete del proyecto, ingresar a la carpeta que contiene app.py y ejecutar los siguientes comandos:

```
python -m venv .venv
# Windows: .venv\Scripts\activate
# macOS/Linux: source .venv/bin/activate
pip install -r requirements.txt
python -m streamlit run app.py
```

Al iniciar, Streamlit abre la aplicación en el navegador. Para que funcione correctamente deben mantenerse las rutas relativas y la estructura de carpetas entregada, especialmente la carpeta modelo/ y sus archivos. Si falta alguno de los artefactos requeridos o las columnas de X_test.csv no coinciden con las que espera el modelo, la aplicación no podrá cargar el flujo de predicción de manera consistente.

Coherencia y alcance del despliegue

El modelo utilizado por AULA corresponde al artefacto exportado desde el proceso de entrenamiento. La aplicación presenta resultados calculados sobre el conjunto de prueba y sus visualizaciones; por ello, esta demostración no equivale a un sistema institucional conectado a bases académicas en tiempo real. Antes de usarla con estudiantes reales sería necesario implementar un formulario de captura con el preprocesamiento idéntico al entrenamiento, controles de calidad de datos, autenticación, protección de información personal, monitoreo y validación institucional.

AULA tiene un propósito académico y demostrativo. Una predicción no constituye un diagnóstico definitivo ni una decisión sobre la permanencia de un estudiante. Cualquier alerta debe ser revisada por personal autorizado y acompañada de una intervención respetuosa, contextualizada y no punitiva.

4. Calidad, limitaciones y proyección

Calidad

La base final tiene 5.000 registros y 313 variables predictoras sin datos faltantes. Se excluyeron 18 columnas relacionadas con cancelar materias o semestres y cambiarse de carrera porque, si se dejaban, revelaban información directamente relacionada con el resultado que se quería predecir y podían producir data leakage. Para llegar a los 5.000 registros se generaron 1.000 registros sintéticos en Python. Para generar cada registro se tomaron dos perfiles reales de la misma categoría de riesgo y se combinaron sus respuestas por bloques de variables.

La similitud entre los registros reales y sintéticos se revisó comparando las proporciones de las variables y sus relaciones con la variable objetivo. En el informe de auditoría se reportó una diferencia promedio de 0,0054 en las proporciones, una diferencia media de correlaciones de 0,0308 y que el 94,94 % de los pares presentó una diferencia de correlación igual o inferior a 0,10. No se encontraron copias exactas entre registros reales y sintéticos ni duplicados entre los sintéticos. Estos resultados respaldan una similitud estadística, pero no demuestran que los registros sintéticos correspondan a estudiantes reales ni que aporten observaciones independientes.

El desempeño fue diferente entre registros reales y sintéticos: el modelo rindió mejor en los registros reales, mientras que en los sintéticos el desempeño fue menor. Por ello, los registros generados deben tratarse como una ampliación aproximada y no como estudiantes reales.

Limitaciones

Pocos perfiles reales distintos: los 4.000 registros reales corresponden a 834 perfiles distintos, aunque la validación agrupada evita que un mismo perfil idéntico quede repartido entre entrenamiento y prueba. La cantidad de perfiles independientes sigue siendo limitada.

Datos sintéticos: los registros sintéticos se parecen estadísticamente a los reales, pero no aportan la información nueva que podrían aportar estudiantes observados. Además, no se conservaron identificadores de parentesco entre los perfiles padres y los registros generados; por eso la separación agrupada no garantiza que se haya eliminado toda dependencia posible entre los sintéticos y sus perfiles de origen.

Variable objetivo: el modelo predice un nivel de riesgo asignado en la base, no una deserción que efectivamente haya ocurrido. La agrupación de las cinco categorías originales en dos clases también fue una decisión metodológica del equipo, especialmente en el límite entre riesgo leve y riesgo medio.

Una sola partición de prueba: los resultados finales se obtienen de un único conjunto de prueba, por lo que su variabilidad en otras particiones no queda completamente caracterizada.

Una sola institución y datos estáticos: los datos proceden de la Universidad Cooperativa de Colombia. No se sabe si el desempeño se mantendría en otras universidades, programas o cohortes. A diferencia del artículo guía, que considera información por fases del semestre, la base utilizada es estática y no permite medir con precisión cuántas semanas antes podría detectarse el riesgo.

No es causalidad: las asociaciones identificadas por el modelo no prueban que las variables sean causas de la deserción. También existe el riesgo de que el modelo aprenda patrones específicos de la base y no generalice a poblaciones diferentes.

Proyección y mejoras

Más datos reales: incorporar observaciones reales de más estudiantes, programas y periodos académicos permitiría reducir la dependencia de datos sintéticos y evaluar mejor la generalización.

Incorporar el tiempo: recopilar información semana a semana permitiría estudiar la evolución del riesgo, establecer ventanas de anticipación y evaluar si las alertas se producen con suficiente tiempo para intervenir.

Umbral de decisión: analizar distintos umbrales de probabilidad permitiría estudiar el equilibrio entre recall y falsas alarmas de acuerdo con la capacidad de acompañamiento de la institución. El umbral debe definirse con criterios académicos y éticos, no solo por maximizar una métrica.

Validación externa: probar el modelo en otra institución o en cohortes posteriores permitiría estimar su estabilidad y detectar cambios en la distribución de los datos o en el desempeño.

Deep Learning: cuando se disponga de un volumen mayor de datos reales y, especialmente, de registros longitudinales, se podrían evaluar redes neuronales para datos tabulares y modelos secuenciales que aprendan cambios en la trayectoria académica. Su comparación debe realizarse con los mismos conjuntos de evaluación y métricas, verificando que la complejidad adicional aporte mejoras reales frente a HistGradientBoosting y que sus resultados puedan explicarse y auditarse.

MLOps: como línea de continuidad, se propone establecer un ciclo de vida controlado para el modelo: versionamiento de datos y artefactos, registro de experimentos, pruebas automatizadas, despliegue reproducible, monitoreo de calidad de entradas y desempeño, detección de cambios en los datos (data drift), revisión periódica de sesgos y mecanismos de reentrenamiento con aprobación humana. Esto permitiría pasar de una demostración académica a un prototipo mantenible, sin asumir que la aplicación actual ya cuenta con esas capacidades.

Uso responsable: cualquier desarrollo futuro debe mantener la supervisión humana, proteger la información personal y evitar que las predicciones se conviertan en etiquetas permanentes sobre los estudiantes. La finalidad debe ser facilitar apoyos oportunos y no restringir oportunidades.

5. Referencias

Jimenez Martinez, A. L., Sood, K., & Mahto, R. (2025). Early Detection of At-Risk Students Using Machine Learning. En Foundations of Computer Science and Frontiers in Education: Computer Science and Computer Engineering (pp. 396–406). Springer. https://doi.org/10.1007/978-3-031-85930-4_36

Mondragon Ramirez, H. S., Bohorquez Bernal, N. S., Nova Martínez, M., & Torres-Londoño, C. I. (2025). Risk of Desertion in Undergraduate UCC [Data set]. Mendeley Data, Version 1. https://doi.org/10.17632/cz6sxh48jm.1

Jimenez Martinez, A. L., Sood, K., & Mahto, R. (2024). Early Detection of At-Risk Students Using Machine Learning. arXiv. https://doi.org/10.48550/arXiv.2412.09483

6. Uso de IA

Durante el desarrollo del proyecto se utilizó inteligencia artificial como herramienta de apoyo en algunas etapas del trabajo, especialmente para la elaboración y revisión de código en Python, la organización de la documentación y el apoyo en la interpretación de resultados y métricas. Las respuestas generadas se revisaron por el equipo y se contrastaron con los resultados obtenidos en el notebook, los archivos del proyecto y las fuentes utilizadas. La selección del modelo, las decisiones metodológicas, la revisión de los resultados y la responsabilidad sobre el contenido final corresponden a los integrantes del equipo: Valentina Bello Olarte y William Gómez Marín.