Nombres: Valentina Bello Olarte y William Gómez Marín

Materia: Machine Learning II

Proyecto Integrador (Entrega 1)

1. ***Problema:***

Las tasas de deserción estudiantil constituyen una preocupación importante tanto en el ámbito educativo como en el de las políticas públicas. Por ello, esta investigación busca identificar con anterioridad qué estudiantes se encuentran en riesgo académico, destacando las complejidades asociadas a dicha identificación y desarrollando un modelo de Machine Learning capaz de detectarlos. El objetivo es proporcionar a los docentes una herramienta que les permita intervenir de manera temprana y garantizar oportunidades educativas equitativas para todos los estudiantes.

El proyecto busca contribuir al éxito académico mediante intervenciones oportunas, asistencia individualizada, espacios de retroalimentación y apoyo específico, con el fin de que los estudiantes superen sus dificultades y alcancen sus objetivos educativos. Un aspecto para comprender los factores que influyen en la deserción es reconocer que abandonar los estudios no es un evento aislado, sino un proceso.

2. ***Enfoque:***

El estudio emplea un enfoque de aprendizaje automático supervisado y se desarrolla en California State University, Fullerton (CSUF). Los autores consideran que el riesgo académico no depende únicamente de las calificaciones y la asistencia, sino también de factores de comportamiento, características demográficas y participación.

3. ***Contexto:***

Los factores asociados al riesgo académico no se limitan a las calificaciones y la asistencia, sino que también incluyen aspectos de comportamiento, demográficos y de participación. El estudio se realiza en la Universidad California State University, Fullerton (CSUF), institución que ofrece 57 programas de licenciatura y cuya tasa promedio de retención de estudiantes entre el primer y segundo año es de 70,57 % para quienes terminan sus estudios en cuatro años o menos, y de 62,7 % para quienes tardan cinco años o más.

Los autores señalan que los modelos predictivos actuales no prestan suficiente atención a los factores de comportamiento y contexto de los estudiantes. Por ello, a diferencia de investigaciones anteriores que han dejado de lado estos aspectos, este

estudio, en el que participan profesores de las áreas de Ingeniería y Ciencias de la Computación, incorpora tres categorías de datos: *engagement* (participación o compromiso del estudiante), *demographics* (datos demográficos) y *grade data* (datos de calificaciones y rendimiento académico).

Los autores destacan que identificar y predecir qué estudiante está en riesgo de reprobar o abandonar sus estudios puede resultar difícil para un profesor que debe hacer seguimiento a un gran número de estudiantes a lo largo de las distintas semanas del semestre.

4. ***¿Para qué?:***

El propósito final es que los docentes puedan intervenir antes de que el estudiante fracase o abandone sus estudios.

Los datos utilizados en la investigación fueron recopilados durante los semestres de otoño de 2023 y primavera de 2024, empleando la plataforma Canvas y el panel institucional de CSUF. El conjunto de datos original contenía 31 variables, los autores construyeron dos conjuntos de características: uno compuesto por 25 variables y otro por las 10 características principales según su relación con la variable objetivo. Finalmente, utilizaron estas 10 características para entrenar los modelos. La muestra estuvo compuesta por 119 estudiantes, de los cuales 21 fueron identificados como en riesgo y 98 como no en riesgo.

Un estudiante se considera "en riesgo" cuando tiene una calificación actual de D o inferior y ha repetido el curso. A partir de esta clasificación, los autores crean la variable objetivo "at-risk", que indica si el estudiante evaluado se encuentra en riesgo (*at-risk*) o no (*not at-risk*). Dado que esta variable tiene dos categorías, el problema se define como uno de **clasificación binaria**.

5. ***Modelamiento:***

El semestre analizado tiene una duración de 16 semanas, comprendidas entre el 20 de enero y el 10 de mayo. Para efectos del modelamiento, los autores dividen el semestre en tres fases:

5.1 División temporal:

Fase 1 : 1–8
Fase 2 : 8–12
Fase 3 : 12–16

Adicionalmente, los profesores participantes deben incorporar evaluaciones formativas en sus clases.

5.2 Modelos considerados:

Para la predicción se evaluaron los siguientes algoritmos de clasificación:

- Support Vector Machines (SVM)
- Naive Bayes (NB)
- K-Nearest Neighbors (KNN)
- Logistic Regression (LR)
- Decision Trees (DT)
- Random Forest (RF)

5.3 Validación del modelo:

Para validar el desempeño de los modelos se emplearon dos estrategias. Por un lado, la técnica de *Train-Test Split*, que divide los datos en un conjunto de entrenamiento y uno de prueba para simular el comportamiento del modelo frente a datos nuevos. Por otro lado, la validación cruzada *K-Fold* (específicamente un 10-fold), que permite estimar de manera más robusta el desempeño del algoritmo sobre el conjunto de datos completo.

Posteriormente, se aplicaron los modelos de clasificación seleccionados utilizando las características escogidas como variables independientes o predictoras, y la predicción *at-risk / not at-risk* como variable de salida.

5.4 Métricas usadas y herramienta de evaluación:

Para evaluar el desempeño de los modelos se emplearon las siguientes métricas:

- **Accuracy (Exactitud):** proporción de resultados correctos entre todos los casos.
- **Precision (Precisión):** proporción de verdaderos positivos entre todos los casos que el modelo predijo como positivos.
- **Recall (Sensibilidad):** proporción de verdaderos positivos entre todos los positivos reales.
- **F1-Score:** media armónica entre Precision y Recall.
- **ROC Curve:** gráfica que representa la tasa de verdaderos positivos frente a la tasa de falsos positivos.

6. Resultados:

Todos los algoritmos evaluados produjeron resultados aceptables, con una exactitud general superior al 78 %. En el texto, los autores señalan a Naive Bayes como el modelo con mejor desempeño general, con una exactitud superior al 89 %. Sin embargo, posteriormente reportan valores de accuracy media superiores para

Decision Tree (0,9745) y Random Forest (0,9847), por lo que existe una aparente inconsistencia en la presentación de los resultados.

7. Análisis del método:

7.1 Método del artículo:

El estudio tiene un enfoque de aprendizaje supervisado en donde las características que se seleccionan previamente actúan como variables predictoras para clasificar a los estudiantes en las categorías at-risk y not-at-risk, este proceso incluye el tratamiento de valores faltantes, la selección de las variables más relevantes y la comparación entre distintos algoritmos de clasificación, también un factor importante es el desbalance entre las clases, se prueban también estrategias de sampling como SMOTE y ADASYN para observar su efecto sobre los resultados.

7.2 Construcción de la variable objetivo:

El modelo utiliza como variable objetivo la condición at-risk. Un estudiante es clasificado como at-risk cuando cumple dos condiciones, la primera es que presenta una calificación actual de D o inferior y la segunda que ha repetido el curso. Esta definición permite transformar el problema educativo en una tarea de clasificación binaria.

8. Supuestos:

El artículo no dedica una sección directa hacia los supuestos del modelo, sin embargo, cuando se revisó las decisiones metodológicas que toman los autores, puede observarse varios supuestos que contiene ya directamente a la construcción aplicación del modelo.

Supuesto 1: Las variables contienen información predictiva

Se parte de la idea de que las características académicas, de rendimiento y de engagement aportan información suficiente para distinguir entre estudiantes at-risk y not-at-risk. Esto queda claro en el propio proceso de selección de variables y en el uso de indicadores como Current Score, GPA, Page Views, Participation y Assignment on Time.

Supuesto 2: La definición de at-risk representa bien el fenómeno

El modelo asume que la forma en que se define el riesgo académico de: nota D o inferior junto con repetición del curso y esto confirma lo que realmente significa estar "en riesgo".

Supuesto 3: Los patrones aprendidos pueden generalizarse

Al usar train-test split y cross-validation, se asume que los patrones identificados en los datos disponibles son válidos para predecir el comportamiento de estudiantes que el modelo no tuvo en cuenta en el entrenamiento.

9. ***Limitaciones:***

A pesar de los resultados positivos que reporta el estudio aún podemos ver que existen algunas limitaciones con respecto al tamaño y composición de los datos, el contexto en el que fueron recolectados y la forma en que se presentan ciertos resultados.

Limitación 1: Tamaño de la muestra

El estudio parte de una muestra de 119 estudiantes, de los cuales solo 21 corresponden a la clase at-risk. Los mismos autores reconocen que se trata de una muestra muy reducida.

Limitación 2: Desbalance de clases

Con 21 estudiantes at-risk frente a 98 not-at-risk, la distribución de clases está claramente desbalanceada, aunque los autores intentan mitigar esto con SMOTE y ADASYN, sigue siendo un factor para tener en cuenta al momento de interpretar los resultados.

Limitación 3: Generalización

Los datos provienen de una sola institución, California State University, Fullerton, por lo que los hallazgos no necesariamente se pueden tener en cuenta para otras universidades o contextos educativos diferentes.

Limitación 4: Estudio preliminar

Los propios autores describen su trabajo como preliminar y mencionan que llevan el análisis con más datos y un componente temporal durante Spring 2024.

Limitación 5: Inconsistencia en los resultados

El artículo comenta que Naive Bayes presenta el mejor desempeño general, sin embargo, posteriormente reporta valores de accuracy media de 0,8937 para Naive Bayes, 0,9745 para Decision Tree y 0,9847 para Random Forest, esto nos dice que existe una aparente inconsistencia entre la afirmación sobre el modelo con mejor desempeño y algunos de los valores reportados posteriormente.

10. ***Adaptación metodológica:***

La metodología del artículo nos servirá como referencia, pero se adaptará al contexto colombiano o latinoamericano, se intentará conservar su cierta lógica general de predicción del riesgo académico, aunque con ajustes en los datos, los modelos, la validación y la interpretación de resultados.

10.1 Elementos que se conservan: Se mantiene el enfoque de clasificación binaria, así como el uso de información de rendimiento académico, características académicas/demográficas y engagement, al igual que la aplicación de técnicas como SMOTE y ADASYN en caso de que exista desbalance entre las clases ya que se considera demasiado importante por el grupo.

10.2 Adaptación de los datos: Este proyecto trabajará con datos de un contexto colombiano o latinoamericano, con un mínimo de 5000 registros, la definición de la variable objetivo como las variables predictoras deberán regularse a partir de la información disponible.

10.3 Modelos: Se tomarán como referencia SVM y Random Forest, ambos empleados también en el artículo original, pero se incorporarán además otros modelos vistos en Machine Learning como las técnicas de Boosting vistas en clase.

10.4 Validación y evaluación: Para la validación la métrica principal se elegirá teniendo en cuenta el tamaño de los errores, dando especial importancia a identificar correctamente a los estudiantes que realmente están en riesgo.

10.5 Interpretabilidad: El proyecto incorporará un componente de interpretabilidad para entender qué variables influyen más en las predicciones del modelo.

11. Planteamiento de nuestro problema:

11.1 Pregunta de investigación

A partir del problema planteado en el artículo, este proyecto busca determinar si es posible identificar tempranamente a estudiantes universitarios en riesgo académico dentro de un contexto colombiano, usando modelos de Machine Learning que integren información sobre rendimiento académico, características académicas o demográficas y nivel de engagement.

11.2 Tipo de identificación

Se trata de un problema de clasificación binaria, en el que el modelo debe asignar a cada estudiante a una de dos categorías, at-risk o not-at-risk.

11.3 Variable objetivo

La variable objetivo corresponde a la condición de riesgo académico del estudiante, la definición exacta se ajustará según las características del conjunto de datos que se obtenga al final y siempre buscando mantener la lógica planteada en el artículo inicial.

11.4 Relevancia en el contexto colombiano

La adaptación del problema al contexto colombiano busca evaluar si es posible utilizar información académica y de participación de los estudiantes para identificar tempranamente posibles casos de riesgo académico, esto podría facilitar la detección oportuna de estudiantes que requieran acompañamiento y permitir que las instituciones educativas orienten sus esfuerzos de apoyo de manera más temprana.

11.5 Método para reproducir y adaptar

Se propone el método de los autores de la usar información del estudiante para plantear una clasificación binaria, seleccionar las variables más relevantes, tener en cuenta el posible desbalance entre clases y comparar distintos modelos predictivos, en esta sección se usaran técnicas de Machine Learning.

12. Estrategia y caracterización de los datos:

12.1 Estrategia de obtención

El proyecto necesita un conjunto de datos correspondiente a un contexto colombiano o latinoamericano, con al menos 5000 registros. Para esto se evaluarán tres alternativas: usar un dataset real, construir una simulación fundamentada o combinar datos reales con datos simulados.

12.2 Características esperadas

El dataset deberá incluir una variable objetivo relacionada con el riesgo académico, y también distintas variables predictoras que representen dimensiones similares a las del artículo original como lo son rendimiento académico, características académicas o demográficas y engagement o participación.

12.3 Calidad de los datos

Antes de comenzar el modelamiento se hará una caracterización inicial del dataset, revisando valores faltantes, tipos de variables, distribución de la variable objetivo, posibles valores atípicos y relaciones entre las variables, con el proposito de definir las transformaciones necesarias antes del modelamiento.

12.4 Tamaño dataset

El conjunto de datos deberá tener al menos 5000 registros, este tamaño nos deja desarrollar las etapas de entrenamiento, validación y evaluación de los modelos con una cantidad de datos mayor a la utilizada en el artículo original.

13. Plan de modelamiento y línea base:

13.1 Modelos avanzados

Se compararán distintos modelos de Machine Learning, tomando como referencia los utilizados en el artículo y dando a las técnicas vistas en Machine Learning. Entre las técnicas se consideran SVM, Random Forest y métodos de Boosting.

13.2 Métrica principal

La métrica principal se definirá teniendo en cuenta el costo de los errores y como el objetivo es detectar correctamente a los estudiantes que están en riesgo, se dará prioridad a reducir los falsos negativos, es decir, los casos en los que el modelo clasifica como not-at-risk a un estudiante que en realidad sí está en riesgo.

13.3 Estrategia de validación

Los modelos se evaluarán mediante particiones de entrenamiento y prueba, complementadas con validación cruzada cuando sea necesario y todo el preprocesamiento.